

PROGETTO 17: GENERAZIONE DI VIDEO IN LINGUA DEI SEGNI

Candidati: Andrea Fiori, Matteo Pedoni, Andrea Unali

Febbraio 2026

Università degli Studi di Sassari - Dipartimento di Ingegneria



SCOPO : Sviluppare una pipeline automatica per tradurre input vocali o testuali in animazioni in lingua dei segni



TARGET : Colmare il divario comunicativo tra udenti e non udenti




STANDARD ADATTATO : American Sign Language(ASL) per ragioni di disponibilità di dataset open-source

OBIETTIVI DEL PROGETTO

ARCHITETTURA DEL SISTEMA

Architettura modulare suddivisa in cinque macro-fasi operative:

- Dataset
- Estrazione Pose
- Acquisizione e trascrizione
- Elaborazione NLP
- Animazione



CREAZIONE DEL DATASET



IL DATASET DI RIFERIMENTO (WASL)



Utilizzo del dataset WASL (Word-Level-American-Sign-Language)



Composto da oltre 2.000 glosse e circa 21.000 video



Selezione Ottimizzata dei download dell'istanza video con durata minore per ogni glossa per semplificare l'estrazione dei keypoints.



Raggiunta una copertura finale del 96% dei gloss previsti tramite strategia di recupero iterativo.

ESTRAZIONE DELLE FEATURES

- Conversione dell'informazione visiva in coordinate spaziali per ridurre il carico computazionale con l'utilizzo di MediaPipe.
- Topologia dei landmark: 57 punti in coordinate (x,y).
- Pre-elaborazione video(OpenCv): Operazioni di decodifica e conversione spazio-colore.

NORMALIZZAZIONE SPAZIALE

- Root centering: tecnica per rendere il modello robusto rispetto alla posizione dell'utente nello spazio:

$$C_{root} = \frac{P_{left_hip} + P_{right_hip}}{2}$$

- Calcolo punto di origine come valore medio tra i due fianchi
- Traslazione di tutti i punti rispetto alla nuova origine:

$$P_{norm} = P_{row} - C_{root}$$


- Output serializzato in formato JSON per interoperabilità e risparmio spazio

ACQUISIZIONE, TRASCRIZIONE ED ELABORAZIONE INPUT

ACQUISIZIONE: WHISPER

- Modello OpenAI WHISPER in un versione ottimizzata per bilanciare accuratezza e velocità
- Architettura Automatic-Speech-Recognition(ASR) basato su Trasformer Encoder-Decoder
- Funzionamento:
 - Conversione dell'audio in spettrogramma Log-Mel
 - Trascrizione robusta multilingue, resistente ai rumori di fondo e accenti

SPETTROGRAMMA LOG-MEL



ELABORAZIONE DEL LINGUAGGIO NATURALE : NLP

- Conversione del testo in una sequenza di glosse compatibile con la lingua dei segni
- Algoritmo di elaborazione :
 - Rimozione punteggiatura e spazi bianchi
 - Filtro ausiliari : rimozione dei verbi ausiliari (es. 'be', 'do', 'can'), per replicare la struttura dei segni
 - Fingerspelling : scomposizione dei nomi propri in singole lettere mappate all'alfabeto manuale
 - Lemmatizzazione : estrazione del lemma in maiuscolo (es. 'running' >> 'RUN')


ELABORAZIONE DEL LINGUAGGIO NATURALE : NLP

Esempi di Traduzione		
Input Audio (Whisper)	Processo SpaCy	Output Glosse (Video)
the two friends are going to school	→ Lemmatization + AUX Filter	TWO FRIENDS GO TO SCHOOL
Andrea can eat a red apple	→ Stop-word Removal + → NER Detection (Name)	A-N-D-R-E-A EAT A RED APPLE

GENERAZIONE VIDEO

SCELTE PROGETTUALI

Sviluppo su piano bidimensionale




SCELTE PROGETTUALI

Valutazione iniziale : Analisi di Blender e del workflow nativo in 3D.

Criticità tecnica : Complessità nella triangolazione delle coordinate XY da inquadrature multiple per il calcolo della profondità (Asse Z).

Pivot progettuale : Passaggio al paradigma 2D tramite lo sviluppo di una libreria Python dedicata per un controllo totale del dato.



SINTESI VISIVA & CLASSE *POSE_LOADER*



Gestione del caricamento e
normalizzazione dei dati cinematici




Normalizzazione temporale : conversione
da frame rate variabili a un target costante




Interpolazione Gerarchica : coordinate
delle dita convertite in locali rispetto al
polso per preservare la struttura durante i
movimenti

CLASSE POSE_LOADER ^{Interpolate}



RENDERING GRAFICO

CLASSE HUMANOID_RENDERED



Motore grafico per tradurre
coordinate in rappresentazione
visiva antropomorfa




Miglioramenti estetici:
arricchimento dello scheletro
con elementi procedurali





Controllo di integrità sulle dite
per evitare glitch


HUMANOID_RENDERED:
create_canvas_gp




HUMANOID_RENDERED: draw_hand



ORCHESTRAZIONE VIDEOCLASSE *ANIMATION_DIRECTOR*



Coordinamento tra caricamento
dati e motore di rendering

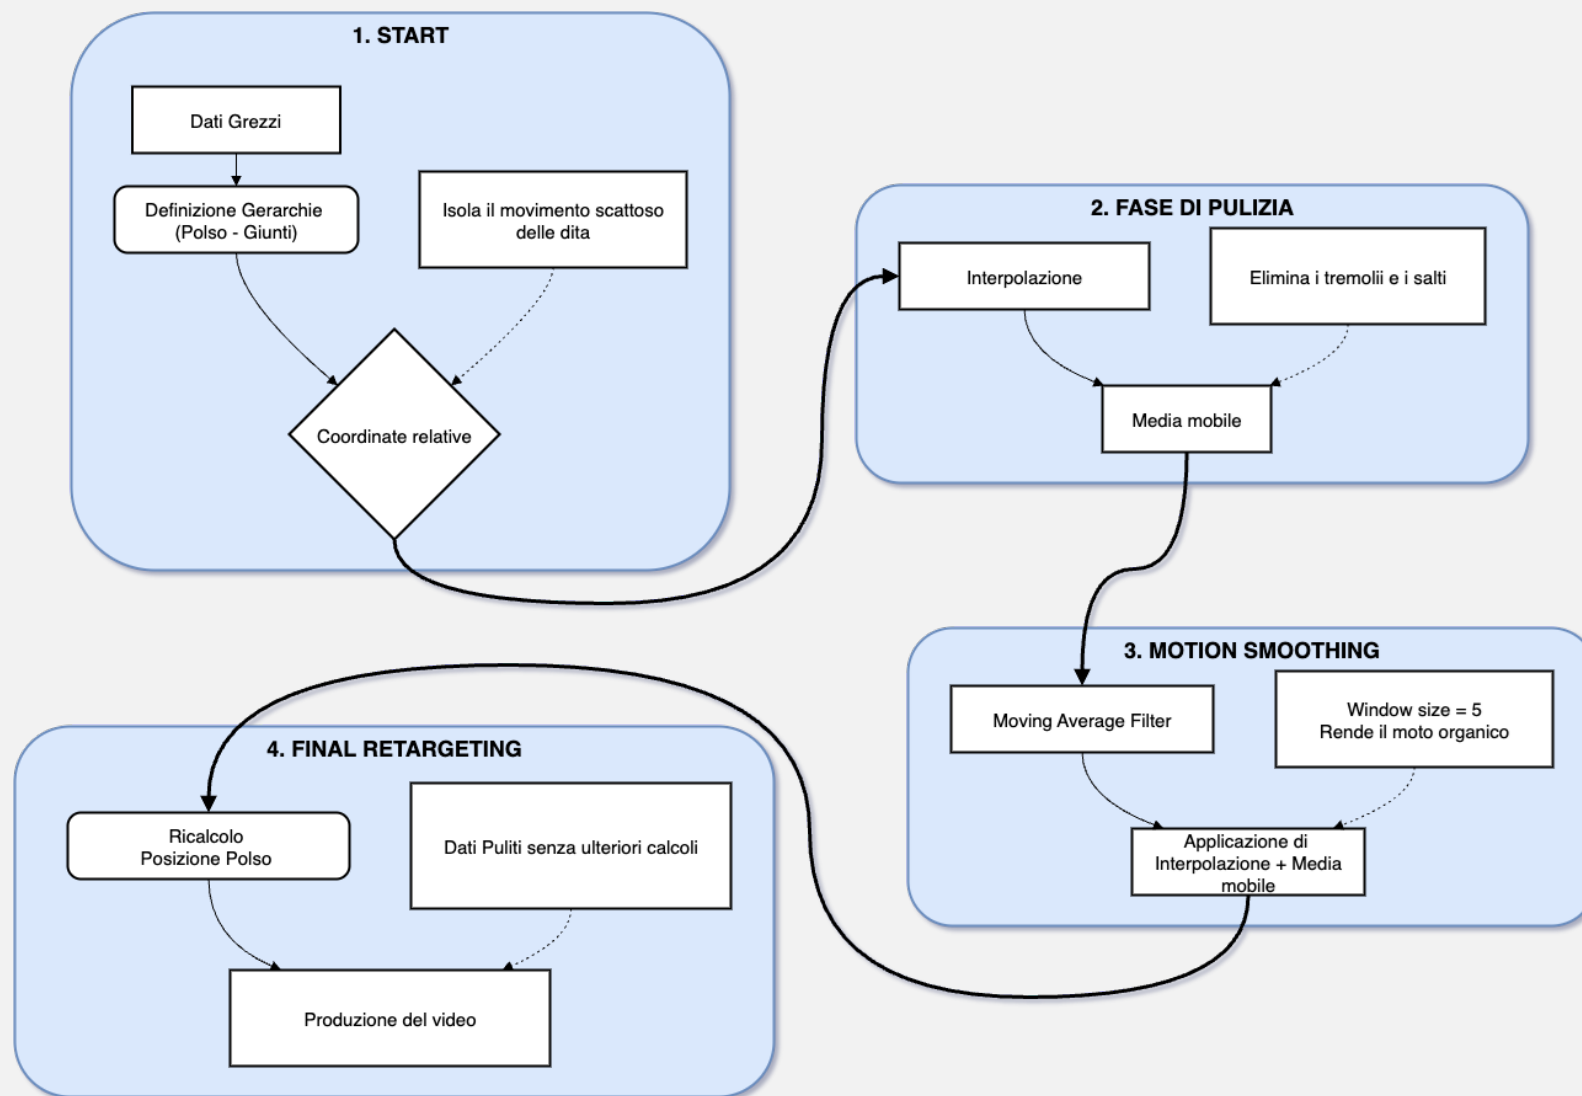


Sintesi di Transizioni : generazione
di frame sintetici intermedi per
eliminare i 'jumpcut'



Utilizzo dell'Interpolazione
Lineare (LERP) sui vettori di posa


CLASSE ANIMATION_DIRECTOR




ANALISI DELLE PRESTAZIONI

Confronto Prestazionale Fasi (Scala Logaritmica)

(Lower is Better)





Parallelismo: Utilizzo dei Thread per Configurazione





Differenze nel MultiThreading

Intel i7 (x86) - Parallelismo Spinto



Molti thread, alta gestione,
minore efficienza per singolo core.

Apple M1 (ARM) - Efficienza Verticale



Pochi thread, bassa latenza,
alta efficienza per singolo core.

Conclusioni e Sviluppi Futuri

TRAGUARDI RAGGIUNTI

Approccio Modulare

Integrazione

Whisper + SpaCy + MediaPipe

Efficacia Visiva

Tecnica

Normalizzazione e Segni Coerenti

Copertura Dataset

Risultato

95% del Dizionario WLASL

Obiettivo Finale

Successo

Accessibilità Universale

EVOLUZIONE E FUTURO

Potenza di Calcolo

GPU

Rendering Real-Time / Unity

Qualità Visiva

Avatar

Modelli 3D Fotorealistici

Espansione LIS

Lingue

Standard Italiani e Internazionali

Grammatica Facciale

Espressione

Integrazione Labiale e Volto

Portabilità

Mobile

Assistente per la Vita Quotidiana

Pose: THANK

